

Salaires au baseball

La performance paie-t-elle?

Analyse statistique des joueurs de MLB
Saison 1992 – 337 joueurs

 UNIVERSITÉ PARIS CITÉ

 Licence 3 | Outils pour la Data Science

 ATIGUI Mohamed

 TAKENNE MEKEM Simeon

 ZEROUALI Amine

 Encadrants : J. Collet & R. Mozet

 [Code source et données \(GitHub\)](#)

Février – Mai 2026

Table des matières

Synthèse	2
Introduction	2
1 Analyse descriptive du jeu de données	2
1.1 Structure du jeu de données	2
1.2 Statistiques descriptives	3
1.3 Répartition des variables de statut contractuel	4
2 Analyses univariées	4
2.1 Distribution du salaire brut	4
2.2 Transformation logarithmique et normalité	5
3 Liaisons avec le salaire	5
3.1 Corrélations linéaires	5
3.2 Indépendance entre variables de statut contractuel	6
3.3 Effet du statut contractuel sur le salaire	7
4 Régressions simples	8
4.1 Comparaison des quatre modèles	8
4.2 Analyse du modèle retenu : $\text{LogSalary} \sim \text{Hits}$	9
5 Régression multiple	10
5.1 Sélection des variables par la méthode Stepwise	10
5.2 Modèle final et interprétation (avec interactions)	10
6 ACP et Classification (réalisées sous R)	12
6.1 Objectif et préparation des données	12
6.2 Choix de l'ACP normée	12
6.3 Choix du nombre d'axes	12
6.4 Interprétation des axes factoriels	13
6.5 Classification Ascendante Hiérarchique	14
Conclusion	16

Synthèse

Les analyses statistiques menées dans ce rapport mettent en évidence quatre résultats majeurs concernant la rémunération des joueurs de la MLB :

- **Le volume prime sur la qualité pure :** Le nombre de coups sûrs (*Hits*) et de points produits (*RBI*) explique près de la moitié de la variance des salaires, loin devant la moyenne au bâton.
- **Le pouvoir de marché est déterminant :** À statistiques égales, un joueur éligible à l'agence libre perçoit un salaire jusqu'à 4 fois supérieur à celui d'un joueur sous contrat restreint.
- **L'arbitrage comme levier d'accélération :** C'est pour les joueurs éligibles à l'arbitrage que la performance marginale (un coup sûr supplémentaire) est la mieux valorisée financièrement (+0.68% par hit).
- **Identification de 3 profils distincts :** L'ACP et la classification mettent en évidence trois typologies claires (Titulaires, Remplaçants, Profils atypiques) corroborant parfaitement la hiérarchie salariale.

Introduction

Le baseball constitue un terrain d'étude privilégié pour l'économiste du travail : les performances individuelles des joueurs sont mesurées de façon précise et standardisée, ce qui permet d'évaluer quantitativement la contribution de chaque employé à la production collective. Ce projet s'inscrit dans cette tradition en cherchant à répondre à une question centrale : **les salaires des joueurs de baseball sont-ils déterminés par leur performance sportive ?**

Nous disposons pour cela d'un jeu de données regroupant 337 joueurs de la *Major League Baseball* (MLB) ayant participé à au moins un match lors des saisons 1991 et 1992 (les lanceurs sont exclus). Pour chaque joueur, nous observons son salaire 1992 (en milliers de dollars), ses statistiques offensives de la saison 1991, ainsi que son statut contractuel (éligibilité à l'agence libre, à l'arbitrage).

La démarche suivie est progressive. Après une analyse descriptive du jeu de données (partie 1) et des analyses univariées (partie 2), nous étudions les liaisons entre le salaire et les variables explicatives (partie 3). Nous construisons ensuite des modèles de régression simple (partie 4) puis multiple (partie 5), avant de clore l'étude par une analyse en composantes principales (ACP) couplée à une classification ascendante hiérarchique (CAH) réalisée sous R (partie 6).

Analyse descriptive du jeu de données

Structure du jeu de données

Le jeu de données comporte **337 observations** et **18 variables**. On distingue :

- 1 variable à expliquer : *Salary*, le salaire 1992 en milliers de dollars;
- 12 variables de performance continue issues de la saison 1991 : moyenne au bâton (*Batting_avg*), pourcentage d'atteinte de la base (*OBP*), nombre de points (*Runs*), de coups sûrs (*Hits*), de doubles, de triples, de home runs (*HR*), de points produits (*RBI*), de buts sur balles (*Walks*), de retraits au

bâton (Strike_outs), de buts volés (Stolen_Bases) et d'erreurs;

- 4 variables binaires de statut contractuel : éligibilité à l'agence libre (Free_agency_elig), statut d'agent libre en 1991/92 (Free_agent_91_92), éligibilité à l'arbitrage (Arbitration_elig), et arbitrage en 1991/92 (Arbitration_91_92).

Valeurs manquantes. Le tableau 1 indique l'absence totale de valeurs manquantes pour l'ensemble des 14 variables continues (N = 337 pour chacune), ce qui simplifie l'analyse.

Statistiques descriptives

TABLE 1 – Statistiques descriptives des variables continues (PROC MEANS)

Variable	N	Moyenne	Médiane	Éc.-type	Min	Max
Salary (k\$)	337	1 248.53	740.00	1 240.01	109	6 100
LogSalary	337	6.535	6.607	1.177	4.691	8.716
Batting_avg	337	0.258	0.260	0.040	0.063	0.457
OBP	337	0.324	0.323	0.047	0.063	0.486
Runs	337	46.70	41.00	29.02	0	133
Hits	337	92.83	91.00	51.90	1	216
Doubles	337	16.67	15.00	10.45	0	49
Triples	337	2.34	2.00	2.54	0	15
HR	337	9.10	6.00	9.29	0	44
RBI	337	44.02	39.00	29.56	0	133
Walks	337	35.02	30.00	24.84	0	138
Strike_outs	337	56.71	49.00	33.83	1	175
Stolen_Bases	337	8.25	4.00	11.66	0	76
Errors	337	6.77	5.00	5.93	0	31

Plusieurs observations ressortent de ce tableau. Le salaire moyen (1 249 k\$) est très supérieur à la médiane (740 k\$), signe d'une forte asymétrie droite : quelques stars tirent la moyenne vers le haut. L'écart-type (1 240 k\$) est du même ordre que la moyenne, traduisant une dispersion considérable. Les variables de performance présentent également une forte hétérogénéité : le nombre de coups sûrs varie de 1 à 216, les home runs de 0 à 44.

Répartition des variables de statut contractuel

TABLE 2 – Répartition des variables de statut contractuel (PROC FREQ)

Variable	Modalité 0		Modalité 1	
	N	%	N	%
Free_agency_elig	203	60.2%	134	39.8%
Free_agent_91_92	298	88.4%	39	11.6%
Arbitration_elig	272	80.7%	65	19.3%
Arbitration_91_92	327	97.0%	10	3.0%

Environ 40 % des joueurs sont éligibles à l'agence libre, ce qui leur confère la liberté de négocier avec d'autres équipes. Seuls 11.6 % ont effectivement exercé ce statut en 1991/92. L'arbitrage reste peu fréquent (moins de 20 % d'éligibles, moins de 3 % l'ayant pratiqué). On notera que les deux statuts sont mutuellement exclusifs dans les données : aucun joueur non-éligible à l'agence libre ne figure parmi les agents libres effectifs.

Analyses univariées

Distribution du salaire brut

Le salaire brut présente une distribution fortement asymétrique à droite (Skewness = 1.16, Kurtosis = 0.67). Le test de Shapiro-Wilk rejette très nettement l'hypothèse de normalité ($W = 0.843, p < 0.0001$). L'histogramme (figure 1) confirme visuellement cette asymétrie : une grande concentration de joueurs dans les tranches basses (moins de 1 000 k\$) et une longue queue à droite avec quelques salaires dépassant 5 000 k\$. Le minimum du salaire (109 k\$, plancher syndical de l'époque) est atteint par plusieurs joueurs, ce qui crée un pic artificiel en bas de la distribution.




FIGURE 1 – Distribution du salaire brut (histogramme et courbe normale ajustée)

Transformation logarithmique et normalité

Afin de pallier l'asymétrie du salaire, nous appliquons une transformation logarithmique : $\text{LogSalary} = \ln(\text{Salary})$. Cette transformation, classique pour des variables de revenus strictement positives et très étalées, produit une distribution nettement plus symétrique (Skewness = -0.07 , quasi nulle).

Cependant, les tests formels de normalité restent significatifs au seuil de 5 % même après transformation (Shapiro-Wilk : $W = 0.934$, $p < 0.0001$; Kolmogorov-Smirnov : $D = 0.102$, $p < 0.01$). Le graphique Q-Q (figure 2) révèle que l'écart à la normalité provient essentiellement des queues : les très petits salaires (plancher syndical) forment un palier en bas, et quelques super-stars créent une légère déviation en haut. Pour la modélisation par régression linéaire, la log-transformation reste justifiée car elle améliore nettement l'ajustement du modèle et rend les résidus plus homogènes.




FIGURE 2 – Distribution du log-salaire

Variable à expliquer retenue. Pour toute la suite, nous modélisons LogSalary plutôt que Salary.

Liaisons avec le salaire

Corrélations linéaires

Le tableau 3 présente les coefficients de corrélation de Pearson entre LogSalary et chacune des 16 variables explicatives. Toutes les variables de performance sont significativement corrélées au seuil de 1 % (sauf Arbitration_91_92 qui atteint $p = 0.054$).

TABLE 3 – Corrélations de Pearson avec LogSalary (PROC CORR, $N = 337$)

Variable	r	p -value	Interprétation
Hits	0.668	< 0.0001	Très forte liaison positive
Runs	0.647	< 0.0001	Très forte liaison positive
RBI	0.652	< 0.0001	Très forte liaison positive
Doubles	0.599	< 0.0001	Forte liaison positive
Walks	0.572	< 0.0001	Forte liaison positive
HR	0.531	< 0.0001	Liaison positive modérée
Free_agency_elig	0.602	< 0.0001	Forte liaison (statut)
Strike_outs	0.414	< 0.0001	Liaison positive modérée
OBP	0.306	< 0.0001	Liaison positive faible
Arbitration_elig	0.251	< 0.0001	Liaison positive faible
Triples	0.274	< 0.0001	Liaison positive faible
Batting_avg	0.266	< 0.0001	Liaison positive faible
Stolen_Bases	0.242	< 0.0001	Liaison positive faible
Free_agent_91_92	0.159	0.0034	Liaison faible
Errors	0.184	0.0007	Liaison positive faible
Arbitration_91_92	0.105	0.054	Non significatif

Les variables Hits ($r = 0.668$), RBI ($r = 0.652$) et Runs ($r = 0.647$) présentent les corrélations les plus fortes avec le log-salaire. Le statut de free agency (Free_agency_elig, $r = 0.602$) est aussi fortement lié au salaire : les joueurs libres de négocier avec d'autres équipes sont mieux rémunérés. À l'inverse, la moyenne au bâton (Batting_avg, $r = 0.266$) et l'OBP ($r = 0.306$), malgré leur pertinence sportive, ont un pouvoir prédictif limité sur le salaire, ce qui suggère que la quantité de jeu (volume) prime sur la qualité pure.

Indépendance entre variables de statut contractuel

Avant d'introduire les variables de statut dans un modèle de régression, nous vérifions leur indépendance deux à deux par des tests du χ^2 (PROC FREQ, option /CHISQ). Les résultats sont présentés dans le tableau 4.

TABLE 4 – Tests d'indépendance du χ^2 entre variables de statut contractuel

Variable 1	Variable 2	χ^2	p -value	Conclusion
Free_agency_elig	Arbitration_elig	53.16	< 0.0001	Dépendantes
Free_agency_elig	Free_agent_91_92	66.81	< 0.0001	Dépendantes
Free_agency_elig	Arbitration_91_92	6.80	0.009	Dépendantes
Arbitration_elig	Free_agent_91_92	10.54	0.001	Dépendantes
Arbitration_elig	Arbitration_91_92	43.13	< 0.0001	Dépendantes
Free_agent_91_92	Arbitration_91_92	1.35	0.245	Indépendantes

Cinq des six paires sont significativement dépendantes. Deux dépendances sont **structurelles** : on ne

peut être agent libre sans y être éligible, et de même pour l'arbitrage. Plus intéressante, la dépendance entre `Free_agency_elig` et `Arbitration_elig` ($\chi^2 = 53.16$) révèle que ces deux statuts sont **mutuellement exclusifs** : aucun joueur n'est à la fois éligible à l'agence libre et à l'arbitrage (cellule = 0 dans le tableau croisé).

Cette exclusivité mutuelle nous amène à construire une variable synthétique `Statut` à trois modalités, fusionnant les deux variables d'éligibilité :

- 0_Aucun : joueur sous contrat restreint (138 joueurs, 41.0 %);
- 1_Arbitrage : éligible à l'arbitrage (65 joueurs, 19.3 %);
- 2_AgentLibre : éligible à l'agence libre (134 joueurs, 39.8 %).

La seule paire **indépendante** est `Free_agent_91_92` $\times$ `Arbitration_91_92` ($\chi^2 = 1.35, p = 0.245$) : ces deux procédures contractuelles sont mutuellement exclusives dans la pratique. Cette variable `Statut` sera utilisée dans la régression multiple (partie 5) en remplacement des deux variables d'éligibilité séparées.

Effet du statut contractuel sur le salaire

Nous réalisons deux tests de Student pour comparer les distributions de `LogSalary` selon le statut contractuel.

Éligibilité à l'agence libre. Les joueurs éligibles à l'agence libre gagnent en moyenne $e^{7.406} \approx 1\,644$ k\$ contre $e^{5.961} \approx 387$ k\$ pour les autres, soit un rapport de **4,2**. Cette différence est hautement significative ($t = -13.79, p < 0.0001$). Les variances étant inégales (test de Levene : $F = 1.54, p = 0.007$), on retient la correction de Satterthwaite, qui confirme le résultat ($t = -14.41, p < 0.0001$).

Statut d'agent libre en 1991/92. Les joueurs ayant exercé leur droit d'agent libre en 1991/92 gagnent en moyenne $e^{7.053} \approx 1\,151$ k\$ contre $e^{6.468} \approx 641$ k\$ ($t = -2.95, p = 0.003$). Cette différence est significative mais plus modeste, et le graphe Q-Q (figure 3) montre que le groupe « agent libre » présente une très bonne adéquation à la loi normale.




FIGURE 3 – Distribution de LogSalary selon le statut de free agency (PROC TTEST)

Ces résultats illustrent l'importance de la liberté contractuelle dans la détermination des salaires : au-delà de la performance sportive, le *pouvoir de négociation* du joueur joue un rôle déterminant.

Régressions simples

Comparaison des quatre modèles

Nous ajustons quatre modèles de régression simple de LogSalary sur les variables de performance les plus corrélées. Les résultats sont résumés dans le tableau 5.

TABLE 5 – Comparaison des régressions simples (PROC REG)

Modèle	r	R^2	p -value (F)	Signe
LogSalary ~ Hits	0.668	0.446	< 0.0001	+
LogSalary ~ RBI	0.652	0.425	< 0.0001	+
LogSalary ~ Runs	0.647	0.419	< 0.0001	+
LogSalary ~ HR	0.531	0.282	< 0.0001	+
LogSalary ~ Batting_avg	0.266	0.071	< 0.0001	+

La variable **Hits** est la meilleure variable explicative simple ($R^2 = 0.446$) : elle explique près de 45 % de la variance du log-salaire. Ce résultat est cohérent avec l'interprétation des auteurs du jeu de données, qui considèrent Hits comme un proxy du temps de jeu effectif. En revanche, la moyenne au bâton (Batting_avg) est un mauvais prédicteur ($R^2 = 0.071$) : la qualité intrinsèque du joueur est moins valorisée que sa présence sur le terrain.¹

1. Les R^2 sont calculés à partir des corrélations de Pearson ($R^2 = r^2$) et confirmés par PROC REG.

Analyse du modèle retenu : $\text{LogSalary} \sim \text{Hits}$

Le modèle estimé par PROC REG est (tous les paramètres sont significatifs à $p < 0.0001$) :

$$\widehat{\text{LogSalary}} = 5.131 + 0.01513 \times \text{Hits} \quad (R^2 = 0.446, \text{RMSE} = 0.877)$$

Le coefficient 0.01513 s'interprète ainsi : un coup sûr supplémentaire est associé en moyenne à une hausse de $e^{0.01513} - 1 \approx \mathbf{1.52\%}$ du salaire. Sur une saison, un joueur passant de 100 à 150 coups sûrs voit son salaire multiplié par $e^{50 \times 0.01513} \approx 2.1$.

Diagnostics (figure 4). Le graphique des résidus en fonction des valeurs prédites montre une légère variation de la dispersion : les résidus sont plus étalés pour les petites valeurs prédites (joueurs peu actifs). C'est assez logique, car le modèle a du mal à différencier les contrats proches du minimum syndical. Le graphique Q-Q indique que les résidus suivent globalement une distribution normale au centre, avec quelques écarts aux extrémités (valeurs atypiques).




FIGURE 4 – Diagnostics d'ajustement du modèle $\text{LogSalary} \sim \text{Hits}$ (PROC REG)

Détection des outliers. Le tableau 6 présente les 10 joueurs dont le résidu positif est le plus élevé, c'est-à-dire ceux dont le salaire dépasse le plus la prédiction basée sur leurs coups sûrs.

TABLE 6 – Top 10 joueurs surpayés par rapport à leurs coups sûrs

Joueur	LogSalary	Prévision	Résidu	Hits
Andre Dawson	8.102	7.446	0.656	153
Steve Buchele	7.863	6.810	1.053	111
Kal Daniels	7.824	6.871	0.953	115
Shawon Dunston	7.814	7.068	0.746	128
Mark Grace	7.746	7.688	0.058	169
Ryne Sandberg	7.685	7.703	−0.018	170
Luis Salazar	6.397	6.432	−0.035	86
Dwight Smith	6.131	5.706	0.426	38
Doug Dascenzo	5.481	6.054	−0.573	61
Sammy Sosa	5.298	6.099	−0.801	64

Ces joueurs sont des **agents libres établis** dont la réputation et le palmarès justifient un salaire supérieur à ce que leurs statistiques de 1991 laissent prévoir : Andre Dawson (MVP 1987) et Ryne Sandberg (futur Hall of Fame) illustrent bien ce phénomène. À l'inverse, les résidus négatifs correspondent à de jeunes joueurs encore sous contrat restreint, tels que Sammy Sosa (résidu = -0.801 , 64 coups sûrs) en début de carrière.

Régression multiple

Sélection des variables par la méthode Stepwise

Afin de construire un modèle plus complet, nous mettons en œuvre une sélection automatique Stepwise via PROC GLMSELECT (critère SBC), en testant deux formulations :

- **Modèle A** : les 4 variables de statut binaires séparées (Free_agency_elig, Arbitration_elig, Free_agent_91_92, Arbitration_91_92);
- **Modèle B** : la variable synthétique Statut (3 modalités, construite en partie 3) combinée à Free_agent_91_92 et Arbitration_91_92, pour tirer parti de l'exclusivité mutuelle mise en évidence par les tests du χ^2 .

Les deux procédures Stepwise convergent vers le **même optimum SBC** (-380.39) et sélectionnent des effets équivalents, confirmant que la variable Statut encode exactement la même information que les deux variables d'éligibilité séparées. On retient le **Modèle B** pour sa lisibilité et sa parcimonie.

Effets retenus (Modèle B). Intercept, Hits, RBI, Statut, Free_agent_91_92.

Modèle final et interprétation (avec interactions)

Afin de respecter la démarche de modélisation attendue, nous avons inclus les croisements entre les variables de performance et le statut contractuel dans la procédure de sélection Stepwise. Le modèle final retenu (étape 5 du critère SBC) inclut une interaction significative, démontrant que la valorisation de la performance dépend du contrat du joueur.

TABLE 7 – Coefficients du modèle final avec croisements (PROC GLMSELECT, $R^2 = 0.797$)

Effet	Estimation	Erreur type	Interprétation
Intercept	6.235	0.139	Niveau de base
RBI	0.0112	0.0022	Production offensive globale
Strike_outs	−0.0034	0.0014	Pénalité pour échec au bâton
Effets de Statut (Base)			
Statut = 0_Aucun	−1.533	0.160	Pénalité forte (contrat restreint)
Statut = 1_Arbitrage	−0.543	0.213	Pénalité modérée (arbitrage)
Statut = 2_AgentLibre	référence	—	—
Prime d'ancienneté			
Free_agent_91_92 = 0	0.305	0.105	Prime pour agents libres anciens
Free_agent_91_92 = 1	référence	—	—
Interaction (Hits × Statut)			
Hits × 0_Aucun	0.0034	0.0014	Valeur d'un hit (contrat restreint)
Hits × 1_Arbitrage	0.0068	0.0016	Valeur d'un hit (arbitrage)
Hits × 2_AgentLibre	0.0050	0.0014	Valeur d'un hit (marché libre)

Qualité d'ajustement. L'inclusion des interactions améliore la qualité du modèle. Le modèle final atteint un $R^2 = 0.797$ (contre 0.789 sans interaction) et la racine de l'erreur quadratique moyenne résiduelle baisse à $RMSE = 0.537$.

Interprétation économique. Quatre enseignements majeurs ressortent de ce modèle complet :

1. **Le statut contractuel domine les salaires de base.** À volume de jeu égal (Hits = 0), un joueur sous contrat restreint subit une pénalité massive de $e^{-1.533} - 1 \approx -78\%$ par rapport à un agent libre. L'arbitrage réduit cette pénalité à environ -42% .
2. **L'effet volume (Hits) dépend du statut (Interaction).** C'est le résultat le plus remarquable. La valeur marginale d'un coup sûr (Hit) varie selon le marché du joueur. Un coup sûr supplémentaire augmente le salaire de $\approx 0.34\%$ pour un joueur sous contrat restreint, de $\approx 0.50\%$ pour un agent libre établi, mais bondit à $\approx 0.68\%$ pour un joueur éligible à l'arbitrage. L'arbitrage est donc le moment de la carrière où chaque coup sûr supplémentaire a le plus d'impact pour faire levier et rattraper le salaire du marché libre.
3. **La qualité offensive et la discipline sont valorisées.** Indépendamment du statut, chaque point produit (RBI) apporte une prime de $e^{0.0112} - 1 \approx +1.13\%$. À l'inverse, un retrait sur des prises (Strike_out) pénalise le salaire de -0.34% .
4. **La collusion envers les nouveaux agents libres.** Le coefficient positif ($+0.305$) pour `Free_agent_91_92 = 0` confirme que les joueurs ayant récemment acquis leur statut d'agent libre en 1991/92 ont été moins bien payés (environ -26%) que les vétérans déjà libres sur le marché, confirmant l'entente tacite des propriétaires de clubs dénoncée à l'époque.

ACP et Classification (réalisées sous R)

Objectif et préparation des données

L'objectif de cette partie est de dégager des **profils types de joueurs** à partir de leurs statistiques offensives, en s'affranchissant de la variable salaire. Nous appliquons successivement une Analyse en Composantes Principales (ACP) sur les 12 variables de performance, puis une Classification Ascendante Hiérarchique (CAH) sur les coordonnées factorielles.

Choix de l'ACP normée

Nous réalisons deux ACP : non normée (matrice de covariance) et normée (matrice de corrélation). L'ACP non normée (figure 5) est dominée par la première composante qui capte à elle seule une variance de $\approx 5\,000$ alors que la seconde n'en capte que ≈ 600 . Ceci s'explique par les différences d'échelle : Hits et Runs ont des variances bien plus grandes que Batting_avg (≈ 0.04). Cette ACP est donc écrasée par les variables au plus grand volume et sera **rejetée**.




FIGURE 5 – Éboulis des valeurs propres

L'**ACP normée** est retenue pour la suite. Chaque variable est centrée-réduite avant l'analyse, garantissant une contribution équilibrée.

Choix du nombre d'axes


Les valeurs propres de l'ACP normée sont : 6.48, 1.53, 1.31, 0.89, 0.61, ... Selon la **règle de Kaiser** (valeurs propres > 1), **3 axes** sont retenus. Ils expliquent cumulativement **77.7 %** de la variance totale (PC1 : 54.0 %, PC2 : 12.7 %, PC3 : 11.0 %).

Interprétation des axes factoriels


TABLE 8 – Loadings des variables sur les 3 premiers axes (ACP normée)

Variable	PC1	PC2	PC3
Batting_average	−0.203	−0.551	0.346
On_base_percentage	−0.228	−0.465	0.409
Number_of_runs	−0.377	−0.017	−0.090
Number_of_hits	−0.370	−0.030	−0.076
Number_of_doubles	−0.344	0.046	0.025
Number_of_triples	−0.206	−0.252	−0.509
Number_of_home_runs	−0.296	0.373	0.254
Number_of_RBI	−0.356	0.225	0.140
Number_of_walks	−0.328	0.060	0.083
Number_of_strikeouts	−0.298	0.364	−0.080
Number_of_stolen_bases	−0.179	−0.294	−0.527
Number_of_errors	−0.153	0.038	−0.253

- **PC1 (54 %) — Axe de volume de jeu.** Tous les loadings sont négatifs : plus un joueur est à gauche sur cet axe, plus il a joué et produit (Hits, Runs, RBI, Doubles). C'est l'axe qui oppose les titulaires réguliers aux remplaçants.
- **PC2 (12.7 %) — Axe puissance vs précision.** Cet axe oppose les joueurs de puissance (HR et strikeouts élevés, valeurs positives) aux joueurs de contact (Batting_avg et OBP élevés, valeurs négatives).
- **PC3 (11.0 %) — Axe vitesse vs puissance.** Cet axe oppose les joueurs rapides (triples, buts volés, valeurs négatives) aux frappeurs de puissance pure (HR).



(a) Plan factoriel 1-2



(b) Plan factoriel 2-3

FIGURE 6 – Biplots de l'ACP normée (variables en rouge, joueurs en gris)

Classification Ascendante Hiérarchique

Choix du nombre de clusters. Nous appliquons une CAH (méthode *complete linkage*) sur les distances euclidiennes calculées dans l'espace des 4 premières composantes principales. Le critère du coude (figure 7) indique un **saut maximal** entre $k = 2$ (hauteur ≈ 14.2) et $k = 3$ (hauteur ≈ 11.6), suivi d'une décroissance progressive. Nous retenons donc $k = 3$ **clusters**.




FIGURE 7 – Critère du coude | CAH après ACP normée

TABLE 9 – Profil moyen des 3 clusters

Statistique	Cluster 1 ($n = 233$)	Cluster 2 ($n = 98$)	Cluster 3 ($n = 6$)
Batting_average	0.267	0.230	0.356
On_base_percentage	0.337	0.288	0.420
Hits	117.7	37.9	23.0
Home_runs	12.1	2.5	0.5
RBI	56.7	16.2	7.5
Walks	44.9	13.3	7.3
Stolen_Bases	10.8	2.7	0.5
LogSalary moyen	6.943	5.663	4.947
Salaire moyen	$\approx 1\,040$ k\$	≈ 288 k\$	≈ 141 k\$
% free agency elig	48.1 %	22.4 %	0.0 %
% arbitration elig	22.7 %	12.2 %	0.0 %

Profils des clusters. Les trois groupes se distinguent clairement :

- **Cluster 1 — Titulaires réguliers (69 % des joueurs).** Ces joueurs présentent un fort volume de jeu

(117 coups sûrs, 56 RBI en moyenne). Leur log-salaire moyen est le plus élevé (6.94) et ils sont les plus souvent éligibles à l'agence libre (48 %).

- **Cluster 2 — Remplaçants (29 % des joueurs).** Peu de coups sûrs (38), peu de RBI (16). Leur salaire est nettement plus bas (log-salaire = 5.66, soit ≈ 288 k\$). Ce cluster correspond aux joueurs peu présents sur le terrain, sous contrat restreint.
- **Cluster 3 — Profils atypiques (6 joueurs).** Ces joueurs se distinguent par une excellente efficacité (Batting_avg = 0.356, OBP = 0.420 — valeurs exceptionnelles) mais un très faible volume de jeu (23 coups sûrs). Leur salaire est minimal (log-salaire = 4.95, ≈ 141 k\$). Il s'agit probablement de jeunes joueurs très habiles mais peu exposés, ou de joueurs en sortie de blessure.




FIGURE 8 – Visualisation des clusters dans l'espace factoriel

La figure 8 (droite) confirme que les 20 salaires les plus élevés (Bonds, Canseco, Fielder, McGriff...) appartiennent tous au **Cluster 1**, et se situent dans la partie gauche du plan factoriel, là où les performances sont les plus élevées. Le volume de jeu est donc bien la principale variable explicative du niveau de salaire.

Conclusion

Cette étude confirme que les salaires des joueurs de baseball en 1992 sont **significativement déterminés par la performance**, mais que cette relation est plus complexe que la simple équation « meilleures stats = meilleur salaire ».

Trois résultats principaux émergent. Premièrement, c'est le **volume de jeu** mesuré par le nombre de coups sûrs, de points marqués ou de RBI qui prédit le mieux le salaire, davantage que des indicateurs de qualité pure comme la moyenne au bâton. Deuxièmement, le **statut contractuel** joue un rôle prépondérant : les agents libres perçoivent un salaire en moyenne quatre fois supérieur à celui des joueurs sous contrat restreint, à performance égale. Cette prime reflète le pouvoir de marché acquis avec la liberté de négociation. Troisièmement, l'ACP couplée à la CAH révèle trois profils de joueurs bien distincts titulaires réguliers, remplaçants, et profils atypiques efficaces mais peu utilisés dont les niveaux de salaire sont parfaitement ordonnés.

Ces résultats sont cohérents avec la littérature en économie du sport et permettent de mieux comprendre pourquoi l'Association des joueurs a obtenu gain de cause dans le litige concernant la sous-rémunération des agents libres en 1991/92 : la régression multiple met en évidence un coefficient négatif pour les agents libres récents, ce qui suggère l'existence d'une entente implicite entre clubs.

Pour de futurs travaux, il serait pertinent d'intégrer des données couvrant plusieurs saisons consécutives afin d'étudier l'évolution des salaires, ou encore d'utiliser des méthodes non linéaires (forêts aléatoires, boosting) pour améliorer les performances prédictives du modèle.

Références

- [1] Watnik, M. R. (1998). *Pay for Play : Are Baseball Salaries Based on Performance ?* Journal of Statistics Education, 6(2).
- [2] Neter, J., Kutner, M. H., Nachtsheim, C. J., & Wasserman, W. (1996). *Applied Linear Statistical Models* (4th ed.). Chicago : Irwin.
- [3] Christensen, R. (1996). *Analysis of Variance, Design and Regression*. London : Chapman and Hall.